


# Búsqueda en línea – Ambientes desconocidos

Julio Godoy  
DIICC





# Hasta el momento..

- Agentes usan algoritmos de búsqueda ‘offline’ (Anchura, profundidad,  $A^*$ , etc..):
  - Calculan una **solución completa** antes de actuar
  - **Sólo** cuando se encuentra una solución, se actúa



# Hasta el momento..

- Agentes usan algoritmos de búsqueda LOCAL:
  - Aún tienen acceso a espacio de estados completo
  - Pero sólo almacenan el estado actual y sus sucesores
  - qué algoritmo usar? → decisión de diseño de la solución



# Ahora..

- Búsqueda en línea:
  - Agente no conoce todo el espacio de estados
    - Restricción del problema!
      - Sólo conoce su estado actual y las posibles acciones.
  - Intercala cómputo y acción:
    - Efectúa una acción
    - Observa el ambiente
    - Calcula la siguiente acción
    - Repite



- Búsqueda en línea es buena idea cuando:
  - Ambiente es dinámico
  - Ambiente es No-determinista



- Búsqueda en línea es NECESARIA cuando:
  - Ambiente es desconocido:
    - Cúales son los estados?
    - Qué hacen mis acciones?
- Agente enfrenta un **problema de exploración**



# Ejemplos


- Robót móvil
  - Exploración, encontrar salida
- Recién nacido



# Problemas de búsqueda en línea

- Por ahora, asumimos un ambiente determinista y observable
- Agentes saben:
  - Acciones (en cada estado)
  - Function de costo  $c(s, a, s')$
  - Test objetivo
- Agentes no saben:
  - Efecto de sus acciones
  - Espacio de estados





**Figure 4.18** A simple maze problem. The agent starts at *S* and must reach *G*, but knows nothing of the environment.

Imagen: Russell y Norvig, 2010



# Objetivo

- Típicamente:
  - Llegar al objetivo minimizando el costo
  - También puede ser: explorar el ambiente
- Desempeño: porción del espacio de estados explorado vs espacio de estados completo



# Problemas

- Caminos sin salida:
  - Si las acciones no son reversibles y se han probado todas las acciones
- Por ahora, suponemos un **espacio de estados seguro de explorar**
  - Ejemplo: puzzle-8, laberinto



# Agentes para búsqueda en línea

- Compara offline vs en línea
  - Piensa en  $A^*$  o búsqueda uniforme
  - ¿Podemos expandir un nodo/estado en **cualquier** ubicación?
  - Ubicación física
  - ¿Podemos adaptar un algoritmo de búsqueda conocido para que funcione en línea?



# Agentes para búsqueda en línea

- Compara offline vs en línea
  - Piensa en  $A^*$  o búsqueda uniforme
  - ¿Podemos expandir un nodo/estado en **cualquier** ubicación?
  - Ubicación física
  - **Búsqueda en profundidad** en línea: sólo con acciones reversibles



```
function ONLINE-DFS-AGENT( $s'$ ) returns an action
  inputs:  $s'$ , a percept that identifies the current state
  static: result, a table, indexed by action and state, initially empty
           unexplored, a table that lists, for each visited state, the actions not yet tried
           unbacktracked, a table that lists, for each visited state, the backtracks not yet tried
            $s$ ,  $a$ , the previous state and action, initially null

  if GOAL-TEST( $s'$ ) then return stop
  if  $s'$  is a new state then unexplored[ $s'$ ]  $\leftarrow$  ACTIONS( $s'$ )
  if  $s$  is not null then do
    result[ $a$ ,  $s$ ]  $\leftarrow s'$ 
    add  $s$  to the front of unbacktracked[ $s'$ ]
  if unexplored[ $s'$ ] is empty then
    if unbacktracked[ $s'$ ] is empty then return stop
    else  $a \leftarrow$  an action  $b$  such that result[ $b$ ,  $s'$ ] = POP(unbacktracked[ $s'$ ])
  else  $a \leftarrow$  POP(unexplored[ $s'$ ])
   $s \leftarrow s'$ 
  return  $a$ 
```

**Figure 4.20** An online search agent that uses depth-first exploration. The agent is applicable only in bidirected search spaces.



# Búsqueda en línea y local

- Recuerda los algoritmos discutidos la clase pasada:
  - ¿Aplicables a búsqueda en línea?



# Búsqueda en línea y local

- Recuerda los algoritmos discutidos la clase pasada:
  - Aplicables a búsqueda en línea?
  - Búsqueda Hill climbing






# Búsqueda en línea y local

- Recuerda los algoritmos discutidos la clase pasada:
  - Aplicables a búsqueda en línea?
  - Búsqueda Hill climbing: óptimos locales...



# Búsqueda en línea y local

- Recuerda los algoritmos discutidos la clase pasada:
  - Aplicables a búsqueda en línea?
  - Búsqueda Hill climbing: óptimos locales...
  - Camino aleatorio!



**Figure 4.21** An environment in which a random walk will take exponentially many steps to find the goal.

Imagen: Russell y Norvig, 2010



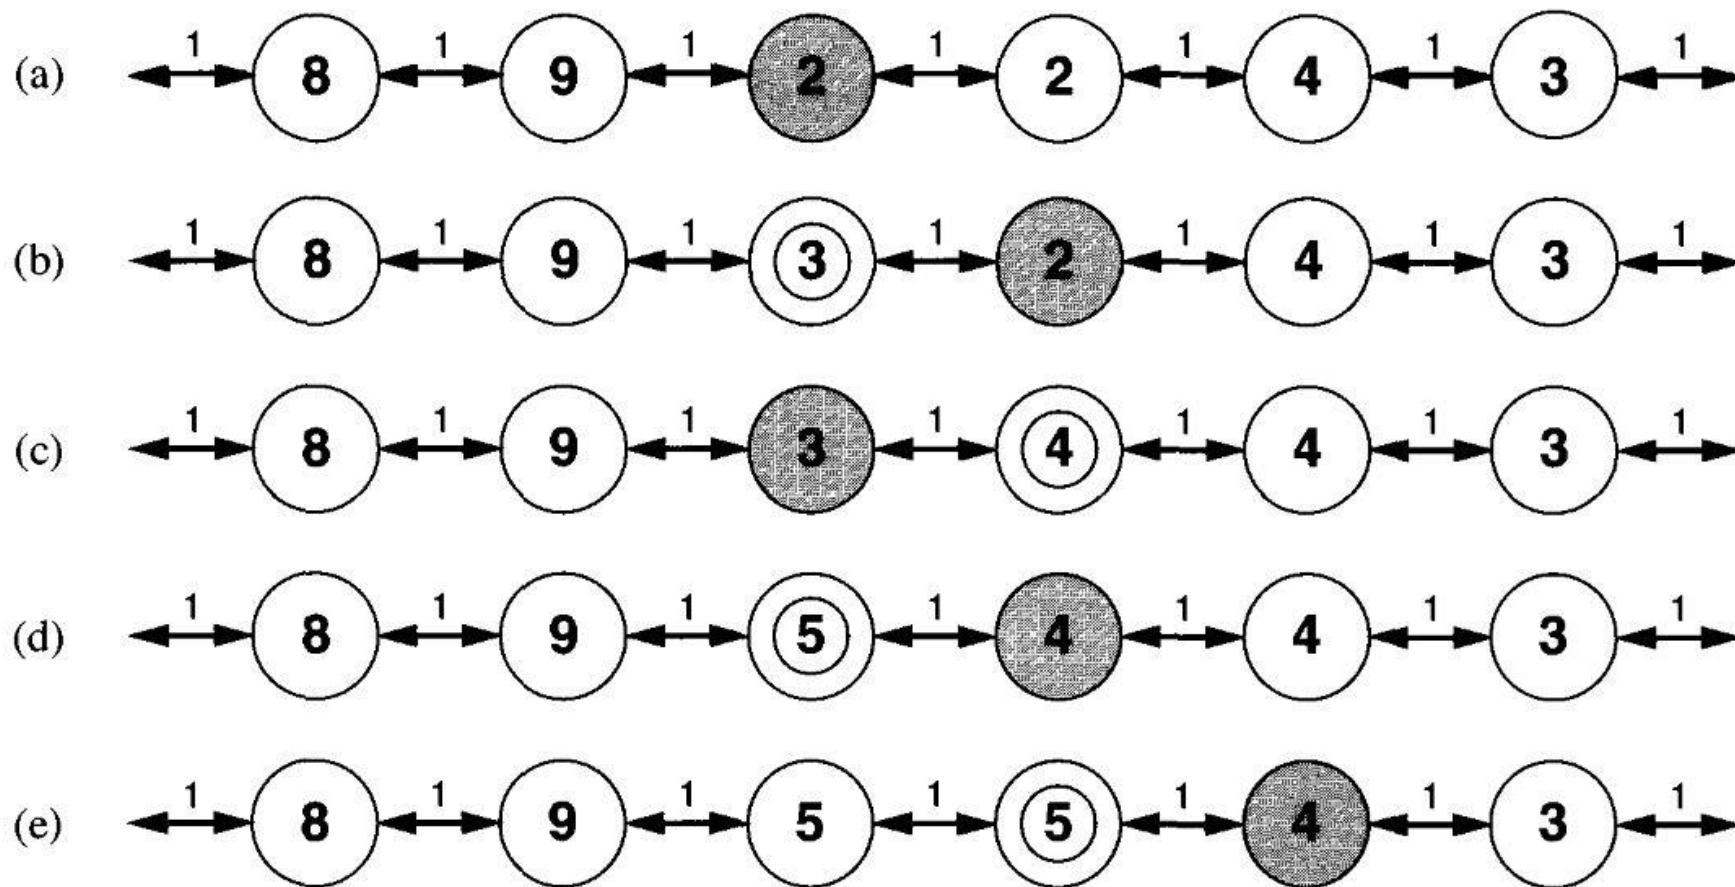
# Búsqueda en línea y local

- Recuerda los algoritmos discutidos la clase pasada:
  - Aplicables a búsqueda en línea?
  - Búsqueda Hill climbing: óptimos locales...
  - Camino aleatorio! → muy ineficiente
  - El agente necesita memoria



# LRTA\*

- Learning Real Time A\*
  - Función de costo  $c(s, a, s')$
  - 'la mejor estimación actual'  $H(s)$
- Crea un 'mapa' basado en las acciones tomadas
- Asume que acciones no tomadas llevan al objetivo



**Figure 4.22** Five iterations of LRTA\* on a one-dimensional state space. Each state is labeled with  $H(s)$ , the current cost estimate to reach a goal, and each arc is labeled with its step cost. The shaded state marks the location of the agent, and the updated values at each iteration are circled.



```
function LRTA*-AGENT( $s'$ ) returns an action
  inputs:  $s'$ , a percept that identifies the current state
  static: result, a table, indexed by action and state, initially empty
            $H$ , a table of cost estimates indexed by state, initially empty
            $s$ ,  $a$ , the previous state and action, initially null

  if GOAL-TEST( $s'$ ) then return stop
  if  $s'$  is a new state (not in  $H$ ) then  $H[s'] \leftarrow h(s')$ 
  unless  $s$  is null
     $result[a, s] \leftarrow s'$ 
     $H[s] \leftarrow \min_{b \in \text{ACTIONS}(s)} \text{LRTA}^*\text{-COST}(s, b, result[b, s], H)$ 
     $a \leftarrow$  an action  $b$  in  $\text{ACTIONS}(s')$  that minimizes  $\text{LRTA}^*\text{-COST}(s', b, result[b, s'], H)$ 
     $s \leftarrow s'$ 
  return  $a$ 

function LRTA*-COST( $s, a, s', H$ ) returns a cost estimate
  if  $s'$  is undefined then return  $h(s)$ 
  else return  $c(s, a, s') + H[s']$ 
```

**Figure 4.23** LRTA\*-AGENT selects an action according to the values of neighboring states, which are updated as the agent moves about the state space.



# LRTA\*



- Garantizado a encontrar el objetivo en ambientes:
  - Finitos
  - Seguro de explorar





# Aprendizaje en búsqueda en línea

- Agente aprende un 'mapa' del ambiente
  - $(s, a, ?)$
- Agente adquiere estimaciones más precisas del costo de un estado



# Aprendizaje en búsqueda en línea

- A

- A  
d

Reinforcement Learning!

s